

UNIVERSIDAD COMPLUTENSE DE MADRID
FACULTAD DE COMERCIO Y TURISMO



TRABAJO DE FIN MÁSTER
“NLP y visualización de Tweets sobre desastres”

Máster en Data Science, Big Data & Business Analytics
Curso 2024/2025

Presentado por
Gerardo J. Alemán, Wilbert Branca, Luis Andrés Oyervides, José Luis Oyervides, Diego Vargas

Tutores:
Carlos Ortega y Santiago Mota

Madrid, 2025

Abstract

Este proyecto presenta el desarrollo de un sistema de clasificación automática de tweets sobre desastres naturales mediante modelos BERT, integrando la recopilación de datos desde la API de X, un proceso de preprocesamiento de texto y una clasificación en tres niveles: detección de tweets informativos, identificación del tipo de desastre y categorización de la información contenida. Para el entrenamiento se utilizó el dataset *CrisisLexT26*, aplicando validación cruzada y ajuste de hiperparámetros para optimizar el rendimiento. Los modelos alcanzaron una precisión del 85.5% en la detección de tweets informativos, 97.6% en la clasificación de eventos de desastre y 69.8% en la categorización de la información.

Como producto final, se desarrolló un dashboard interactivo con Dash, que permite visualizar la distribución de los tweets clasificados y analizar tendencias en la conversación sobre desastres. Los resultados demuestran la efectividad del uso de BERT en el monitoreo de crisis mediante redes sociales, ofreciendo una herramienta escalable para la gestión de emergencias. Futuras mejoras incluyen la optimización del pipeline para su implementación en entornos operativos y la integración con técnicas avanzadas de clasificación y geolocalización.

Todo el código, así como los *notebooks* usados para preprocesar, entrenar modelos y visualizar, se pueden encontrar en el siguiente repositorio de Github:

<https://github.com/TFM-DisasterLab/NLP-y-visualizacion-de-Tweets-sobre-desastres/tree/main>

ÍNDICE

1. Introducción

- Contexto y relevancia del análisis de datos en desastres naturales.
- Importancia del procesamiento de lenguaje natural (NLP) en redes sociales.
- Objetivo general y específicos del proyecto.

2. Investigación

- Revisión de estudios previos relacionados con NLP y desastres naturales.
- Herramientas y enfoques comunes para la clasificación y visualización de tweets.

3. Metodología y Desarrollo

- Análisis Exploratorio de Datos (EDA) del dataset *CrisisLexT26*.
- Preprocesamiento de datos.
- Desarrollo y entrenamiento de modelos.
- Integración con la API de Twitter para obtener tweets recientes.
- Desarrollo del Dashboard interactivo.
- Evaluación de desempeño con tweets recientes.

4. Producto entregable

- Presentación de resultados en el Dashboard.
- Conclusión Final.

5. Referencias

6. Anexos

1. INTRODUCCIÓN

Contexto y relevancia del análisis de datos en desastres

Cada año, desastres naturales como terremotos, huracanes, inundaciones e incendios forestales afectan a millones de personas en todo el mundo. Solamente en 2023, se registraron hasta 398 catástrofes en todo el mundo, dando como resultado la pérdida de 74,000 vidas (Fernández, 2025b). Pero el impacto de estos eventos va más allá, pues también generan pérdidas económicas y ambientales significativas. En el mismo año, las pérdidas materiales a nivel mundial ascendieron hasta 380,000 millones de dólares estadounidenses (Fernández, 2025a). Todo esto, subraya la importancia de herramientas efectivas para la gestión de estas catástrofes.

Por otro lado, la rápida evolución de tecnologías digitales ha permitido generar y recopilar grandes volúmenes de datos en tiempo real, provenientes de sensores, redes sociales y dispositivos móviles. Estos datos son una oportunidad sin precedentes para entender, monitorear y responder a emergencias. Particularmente, plataformas como X (anteriormente Twitter) se han convertido en canales esenciales para la comunicación durante desastres, permitiendo a las personas compartir información, solicitar ayuda y reportar daños. Un estudio publicado en el *International Journal of Disaster Risk Reduction* en 2022 analizó datos provenientes de redes sociales como X y Telegram relacionadas con las inundaciones del 2018 en Kerala, India. Estos datos se contrastaron con información de fuentes gubernamentales e institucionales diseñadas para registrar y gestionar la respuesta al desastre. El estudio concluyó que las redes sociales son una herramienta eficaz para recopilar información validada y analizar áreas afectadas por desastres naturales, ya que permiten generar hallazgos útiles y obtener datos de forma más rápida y accesible que por otros medios tradicionales (Young et al., 2022).

Durante un desastre, las personas en las zonas afectadas tienden a publicar actualizaciones sobre su situación, compartir imágenes o videos del evento y solicitar asistencia inmediata. Este flujo constante de información es invaluable, pero también presenta desafíos importantes, como el manejo del volumen masivo de datos, la identificación de contenido relevante y validación de la información compartida. En este contexto, la ciencia de datos, y en particular, el procesamiento de lenguaje natural (NLP, por sus siglas en inglés), emerge como una herramienta poderosa para enfrentar estos desafíos.

Importancia del procesamiento de lenguaje natural (NLP) en redes sociales

Durante un desastre natural, las redes sociales como X se llenan de publicaciones que describen la situación en las zonas afectadas. Estas pueden incluir solicitudes de ayuda o información sobre necesidades específicas, reportes de daños a infraestructuras, como puentes o edificios; alertas tempranas sobre eventos secundarios, como inundaciones repentinas o réplicas de un terremoto.

El NLP permite filtrar y priorizar esta información, identificando automáticamente los mensajes más relevantes. Por ejemplo:

- Clasificación de contenido: separar tweets relacionados con desastres de aquellos que no tienen relación.
- Reconocimiento de entidades nombradas: extraer ubicaciones, nombres de organizaciones o recursos mencionados en los textos.
- Análisis de sentimientos: evaluar el tono emocional de las publicaciones, lo que puede ser útil para identificar situaciones críticas o evaluar el impacto en la comunidad.

Por otro lado, el texto generado en redes sociales es altamente desestructurado y a menudo presenta desafíos únicos, ya sea por uso de lenguaje coloquial, abreviaturas, emojis, mezcla de idiomas, además de ruido que resulta de spam o mensajes irrelevantes. Por eso, las técnicas de NLP, como la tokenización, la lematización y la eliminación de stopwords, son esenciales para limpiar y normalizar este tipo de datos.

Una vez procesados, los datos de texto pueden analizarse para identificar patrones emergentes mediante técnicas como *clustering* o modelos tópicos (LDA) para identificar temas latentes y comprender mejor las preocupaciones predominantes durante un desastre. Por ejemplo, durante un huracán, el NLP puede agrupar mensajes relacionados con inundaciones en un área específica, problemas de transporte o cortes de electricidad, proporcionando un panorama temático de la situación.

El procesamiento de texto por medio de NLP también los prepara para su visualización. Esto permite generar mapas de calor geoespaciales que muestran dónde se concentran las menciones de ciertos términos clave, crear gráficas temporales que ilustran tendencias en el tiempo, como un aumento en las solicitudes de ayuda, y hasta dashboards interactivos que destacan temas emergentes, ubicaciones críticas y necesidades prioritarias.

A diferencia de los métodos manuales, las técnicas de NLP son escalables y capaces de procesar millones de mensajes en tiempo real. Esto resulta especialmente relevante durante emergencias, donde cada segundo cuenta para tomar decisiones informadas.

Objetivo general y específicos del proyecto

En este proyecto, pretendemos desarrollar un sistema automatizado que clasifique y visualice los tweets relacionados con desastres, utilizando técnicas de NLP y aprendizaje no supervisado, con el fin de apoyar la toma de decisiones en la gestión y respuesta a emergencias.

Objetivos específicos:

- Preprocesar los datos textuales de un conjunto de datos de X para su análisis y aplicar técnicas de NLP, como tokenización, eliminación de ruido y normalización para preparar los textos.
- Entrenar y evaluar modelos de aprendizaje para catalogar tweets relacionados con desastres.
- Configurar la API de X para recopilar tweets recientes relacionados con desastres.
- Incorporar los modelos entrenados para procesar y analizar estos datos recientes.
- Crear un sistema de visualización que permita explorar los resultados del análisis de manera gráfica y que facilite la interpretación de los datos procesados.
- Validar y evaluar el sistema, asegurando que cumpla con los objetivos de precisión, velocidad y utilidad práctica.

Al combinar el análisis histórico de datos con flujos recientes, esta solución busca demostrar el potencial transformador de las tecnologías digitales para salvar vidas y mitigar el impacto de los desastres naturales.

2. INVESTIGACIÓN

Revisión de estudios previos relacionados con NLP y desastres naturales.

El campo de *crisis informatics* ha explorado ampliamente cómo los datos generados por usuarios en redes sociales pueden contribuir a la gestión de desastres. Las redes sociales como X se han convertido en fuentes valiosas de información en tiempo real, utilizadas en tareas como la detección de brotes, la evaluación de daños y el análisis del comportamiento de evacuación.

Un estudio de la Universidad de Stanford, titulado *Tweets Classification with BERT in the Field of Disaster Management* (Ma, 2020), analiza cómo los modelos basados en BERT pueden mejorar la clasificación de tweets relacionados con desastres. El autor destaca que las técnicas tradicionales de clasificación, como los modelos de soporte vectorial (SVM), bayesianos y LSTM con embeddings de GloVe, enfrentan limitaciones al trabajar con grandes volúmenes de texto no estructurado y datos etiquetados de manera inconsistente.

En este proyecto, BERT demostró un rendimiento superior, mejorando la precisión en un 3.29% en comparación con los modelos base. Los tweets se clasificaron como “daños a infraestructura”, “personas afectadas”, “advertencias y consejos”, entre otras. Estas etiquetas ofrecen una visión detallada de la situación en el terreno durante un desastre.

El estudio también aborda los desafíos asociados con la ambigüedad y la subjetividad en los textos. Tweets cortos, mensajes sarcásticos o aquellos que contienen palabras clave ambiguas representan dificultades para los modelos, lo que afecta su capacidad para distinguir entre información relevante e irrelevante.

Estos hallazgos subrayan la importancia del procesamiento de lenguaje natural para mejorar la gestión de datos sociales en situaciones de emergencia. Modelos avanzados, como los basados en BERT, no solo aumentan la precisión en la clasificación, sino que también permiten extraer información procesable de grandes volúmenes de texto en tiempo real, un recurso crucial para la toma de decisiones durante desastres.

El conjunto de datos *CrisisLexT26* es ampliamente utilizado en investigaciones sobre la clasificación de textos relacionados con desastres naturales. Este dataset fue compilado por Alexandra Olteanu et al. como parte de la iniciativa *CrisisLex*, cuyo objetivo es facilitar el análisis de mensajes generados en redes sociales durante crisis. Contiene mensajes (principalmente tweets) recopilados durante 26 eventos de desastres distintos, incluyendo

huracanes, terremotos, inundaciones y ataques terroristas (Olteanu, Vieweg, & Castillo, 2015).

Otro estudio relevante en el campo de la gestión de desastres es *A Twitter Tale of Three Hurricanes*, de Firoj Alam et al. (2018), en el que se realizó un análisis extenso de los datos generados en Twitter durante los huracanes Harvey, Irma y María en 2017. Este trabajo pone en evidencia cómo las plataformas se utilizan masivamente en situaciones de emergencia, proporcionando información tanto textual como multimedia que puede ser de gran utilidad para los equipos de respuesta.

El estudio recopiló más de 9 millones de tweets a través de la API de Twitter durante estos eventos y empleó técnicas de NLP y aprendizaje automático para clasificar los mensajes en categorías humanitarias, usando casi las mismas etiquetas que el estudio mencionado previamente.

Asimismo, una de las contribuciones más importantes de este estudio es que demuestra cómo las discusiones en redes sociales cambian a lo largo de las diferentes fases del desastre (pre, durante y post impacto). Por ejemplo, se observó que durante la fase inicial de los huracanes, predominan los mensajes de advertencia y consejos, mientras que en las fases posteriores aumentan las solicitudes de ayuda y los reportes de daños.

El análisis incluyó técnicas de modelado de temas (*topic modeling*) utilizando LDA (Latent Dirichlet Allocation) para identificar automáticamente temas emergentes relacionados con las necesidades de los afectados. También se aplicó reconocimiento de entidades nombradas (*Named Entity Recognition*) para extraer ubicaciones, nombres de personas y organizaciones relevantes, lo que ayuda a los equipos de respuesta a priorizar acciones en áreas específicas.

El estudio subraya la importancia de los sistemas automatizados para manejar grandes volúmenes de datos durante desastres, permitiendo a las autoridades mejorar la conciencia situacional (*situational awareness*) y la coordinación de recursos en tiempo real. Los hallazgos también resaltan la necesidad de combinar enfoques supervisados y no supervisados en el análisis de datos sociales para maximizar la utilidad de la información.

Herramientas y enfoques comunes para la clasificación y visualización de tweets

El procesamiento de texto es esencial para convertir los tweets, que suelen ser desestructurados y ruidosos, en información procesable. Entre las herramientas más utilizadas se incluyen:

- **NLTK (Natural Language Toolkit)** y **spaCy**: librerías usadas para tareas de preprocesamiento como tokenización, lematización, eliminación de stopwords y análisis sintáctico.
- **Hugging Face Transformers**: ofrece implementaciones pre entrenadas de modelos como BERT (Bidirectional Encoded Representations from Transformers), que han demostrado ser altamente efectivas para tareas de clasificación de texto.
- **Stanford CoreNLP**: un toolkit que permite realizar reconocimiento de entidades nombradas (NER), análisis de sentimientos y otras tareas.

Para clasificar los tweets según su contenido, se utilizan tanto modelos supervisados como no supervisados. Algunos enfoques comunes incluyen:

- Random Forest, Naïve Bayes y SVM, que han sido utilizados tradicionalmente para la clasificación básica de tweets.
- Modelos de redes neuronales, como LSTM y CNN, que aprenden de patrones complejos en los modelos textuales, ofreciendo mejores significativas.
- Modelos basados en BERT, que han demostrado superar los enfoques tradicionales al capturar mejor el contexto semántico en textos breves, como es en el caso de los tweets.
- Algunos modelos no supervisados como de Clustering (K-means o DBSCAN) se utilizan para agrupar tweets en temas o categorías emergentes.

Una visualización efectiva es fundamental para que los responsables de la toma de decisiones comprendan rápidamente la magnitud de la crisis y las necesidades prioritarias. Entre las herramientas más útiles podemos incluir:

- **Dash y Streamlit:** Frameworks en Python para crear dashboards interactivos que permiten visualizar mapas geoespaciales, gráficas de líneas temporales y nubes de palabras.
- **Tableau y Power BI:** herramientas comerciales que facilitan la creación de visualizaciones dinámicas con datos.
- **Folium y Plotly:** librerías de Python que permiten la visualización de datos geoespaciales y gráficos interactivos.

La combinación de herramientas de procesamiento de texto, técnicas de aprendizaje automático y herramientas de visualización permite crear sistemas robustos que son capaces de analizar y presentar información crítica durante desastres. Estos enfoques mejoran la eficiencia de los equipos de respuesta al proporcionarles una comprensión más rápida y precisa de la situación.

3. METODOLOGÍA Y DESARROLLO

Análisis Exploratorio de Datos (EDA) del dataset *CrisisLexT26*

El dataset analizado consta de un total de 74,346 registros al quitar tweets con una longitud menor a 4 caracteres y está compuesto por siete columnas: *InformationType*, *event*, *TweetID*, *TweetText*, *location*, *year* y *Informativeness_label*. Todas las columnas son de tipo objeto y hemos identificado valores nulos en las variables *TweetID* (733 valores faltantes) y *location* (8 valores faltantes).

En relación con la variable de clasificación, el dataset divide los tweets en dos categorías: informativos y no informativos. Se observa que el 52.4% de los tweets han sido clasificados como “No relacionados o no informativos”, mientras que el 47.6% se consideran “Informativos”. Esta distribución muestra que casi la mitad del conjunto de datos contiene información directa sobre eventos de desastre, lo que evidencia una gran cantidad de datos relevantes para la identificación y monitoreo de estos eventos.

El análisis de la variable *event* indica que los eventos de desastre más mencionados en los tweets incluyen huracanes, deslizamientos de tierra, terremotos, inundaciones e incendios forestales. La alta frecuencia de estos eventos nos dice que ciertos tipos de desastres generan un mayor nivel de interacción y discusión en redes sociales, lo que puede reflejar su impacto en la población y la cobertura mediática que reciben.

A partir de estos hallazgos, los próximos pasos serán el manejo adecuado de valores nulos y la aplicación de técnicas de preprocesamiento de texto para la variable *TweetText*.

Preprocesamiento de datos

El preprocesamiento del dataset se realizó con el objetivo de limpiar y normalizar el texto de los tweets, eliminando elementos irrelevantes y reduciendo el ruido para mejorar el análisis posterior. Se generó una nueva columna *PreprocessedText*, a partir de una copia del texto original (*TweetText*). Se eliminaron las URLs, menciones a usuarios (@usuario) y encabezados de re-tweets (RT @usuario), que no aportaban información relevante al contenido del tweet. Asimismo se eliminaron caracteres no ASCII, es decir, caracteres como emojis y otros símbolos, dejando únicamente texto en inglés estándar. Se reemplazaron entidades HTML por sus equivalentes (e.g. “&” por “and”) para mejorar la legibilidad

del texto. Se hizo limpieza adicional para eliminar guiones bajos, repeticiones de palabras, hashtags y palabras con números; se separaron palabras y caracteres especiales que estaban pegados entre sí y se normalizaron los espacios en blanco, eliminando múltiples espacios consecutivos. El texto se transformó a minúsculas para mantener la uniformidad y se añadió una nueva columna, “*PreprocessedText_length*” que contiene la cantidad de palabras en el texto procesado, permitiéndonos analizar la distribución de la longitud de los tweets.

Desarrollo y entrenamiento de modelos

Para este proyecto, se entrenaron tres modelos de clasificación BERT-base uncased para la clasificación de tweets relacionados con desastres. Cada modelo se enfocó en una tarea específica: determinar si un tweet es informativo o no (*Informativeness_label*), identificar el tipo de desastre mencionado (*event*) y clasificar la categoría de información proporcionada (*InformationType*). Se emplearon técnicas de validación cruzada y mecanismos de regularización, como *dropout* y *early stopping*, para optimizar el desempeño de cada modelo.

El modelo de *Informativeness_label* alcanzó una precisión del 85.5% en el conjunto de prueba, con una pérdida final de 0.3664. Se observó un alto *recall* en la clase “*informative*” (92.8%), lo que indica que el modelo detecta bien los tweets relevantes, aunque tuvo un desempeño menor en la clase *not informative* (75.1% de *recall*), sugiriendo oportunidades de mejora en la reducción de falsos positivos.

Para la clasificación de eventos de desastres, el modelo alcanzó una precisión del 97.6% en el conjunto de prueba, tras tres épocas de entrenamiento y validación cruzada con 3 *folds*. Su alto rendimiento se debe a la naturaleza estructurada de los tweets sobre desastres, donde términos como “*earthquake*” o “*hurricane*” aparecen en contextos bien definidos, facilitando la identificación de patrones semánticos.

Finalmente, el modelo para *InformationType* obtuvo una precisión del 69.7% en el conjunto de prueba, con una pérdida final de 0.8323. Se desempeñó bien en clases como *not related or not informative* (F1-score: 0.759) y *affected individuals* (F1-score: 0.759), pero mostró menor precisión en categorías como *caution and advice* (F1-score: 0.529) e *infrastructure and utilities damage* (F1-score: 0.584). Esto sugiere que algunas clases podrían beneficiarse de técnicas adicionales, como balanceo de datos o *data augmentation* para mejorar su representatividad.

Los tres modelos fueron almacenados para su integración en el *pipeline* de clasificación de tweets en tiempo real.

Integración con la API de X para obtener tweets recientes

Se implementó un *pipeline* automatizado que permite obtener, pre procesar y clasificar tweets recientes utilizando la API de X y los modelos entrenados. Este flujo de trabajo consta de las siguientes etapas:

1. Extracción de tweets: la obtención de datos se realiza mediante Tweepy, utilizando el bearer token de la API de X. Se configuran filtros de búsqueda, incluyendo términos clave y exclusión de retweets, para recuperar únicamente tweets relevantes sobre desastres. Se extraen campos como ID del tweet, fecha de creación, texto, ubicación y estado de verificación del usuario.
2. Procesamiento de los tweets: los tweets obtenidos son almacenados en un archivo CSV y luego pasan por un *notebook* de preprocesamiento, donde se aplican técnicas de limpieza y normalización iguales a las que se aplicaron con los datos de entrenamiento.
3. Clasificación por *Informativeness*: una vez preprocesados, los tweets ingresan al primer modelo BERT, encargado de predecir la variable *Informativeness_label*, clasificando cada tweet como informativo o no informativo.
4. Identificación del tipo de desastre: los tweets informativos son analizados por el segundo modelo BERT, que predice la variable *event*, clasificando el tweet según el tipo de desastre que describe (ej. *earthquake*, *hurricane*, *floods*). Esta etapa permite segmentar y categorizar los eventos con mayor precisión.
5. Clasificación del tipo de información: finalmente, los tweets pasan por el tercer modelo BERT, que asigna etiquetas a la variable *InformationType*, clasificando el contenido del tweet en categorías como *afectados*, *advertencias*, *donaciones*, *daños a infraestructuras*, entre otras. Esto facilita la interpretación del tipo de información contenida en cada tweet.
6. Almacenamiento y Visualización: los tweets clasificados se integran en un dataset estructurado, incluyendo variables adicionales obtenidas de la API de X ya mencionadas. Este dataset se utiliza para alimentar un dashboard interactivo, donde los datos pueden visualizarse, permitiendo el análisis de la información recolectada.

Desarrollo del Dashboard interactivo

Para visualizar y analizar los datos obtenidos a partir de la API de X y el *pipeline* de clasificación de modelos BERT, se desarrolló un dashboard interactivo utilizando Dash y Plotly, proporcionando una exploración estructurada de los datos a mediante visualizaciones dinámicas y filtros interactivos. Este dashboard permite analizar tendencias en la conversación digital sobre desastres y facilita la interpretación de los resultados obtenidos en el *pipeline* de clasificación.

Su desarrollo se realizó utilizando las siguientes tecnologías:

- Dash (Plotly): Framework en Python para construir aplicaciones web interactivas.
- Plotly Express: biblioteca para la generación de gráficos dinámicos.
- Pandas: manipulación y filtrado de datos.
- Dash DataTable: visualización interactiva de datos tabulares.

El diseño del dashboard sigue un enfoque modular y responsivo, asegurando una interfaz clara, accesible y adaptativa para la exploración de los datos. Se añadieron menús desplegables que permiten filtrar los tweets por tipo de desastres y categoría de información para visualizar los tweets relacionados con un evento específico y facilitar la identificación de los temas predominantes en la conversación. También se implementaron *callbacks* para que los gráficos se actualicen en tiempo real según los filtros seleccionados.

A grandes rasgos, el dashboard está compuesto por varias secciones clave:

1. Distribución de tweets por informatividad: gráfico de pastel que muestra la proporción de tweets clasificados como informativos y no informativos (Modelo 1). Esto permite evaluar qué porcentaje del dataset contiene información relevante para el análisis.
2. Clasificación de tweets por tipo de desastre: mediante gráfico de barras representa la cantidad de tweets clasificados por su categoría de desastre (Modelo 2). Así, ayuda a analizar qué desastres naturales tienen mayor presencia en la conversación digital.
3. Distribución del tipo de información: con otro gráfico de barras interactivo, podemos ver la cantidad de tweets clasificados en cada tipo de información (Modelo 3),

identificando las principales temáticas (advertencias, donaciones, daños en infraestructuras, etc.).

4. Exploración de tweets clasificados: a través de una tabla dinámica se muestran los tweets analizados junto con su clasificación en los tres modelos. Esto permite a los usuarios examinar el contenido real de los tweets y su categorización. Se actualiza en función de los filtros aplicados.

El desarrollo del dashboard permite convertir los datos clasificados en una herramienta visual de análisis, facilitando la interpretación de los tweets sobre desastres. Su implementación en Dash ofrece una plataforma interactiva y escalable, que en el futuro puede ampliarse con nuevas funcionalidades como filtros avanzados y mapas de geolocalización de tweets.

Evaluación de desempeño con tweets recientes

Para evaluar el rendimiento del sistema en un entorno real, se realizó una prueba obteniendo un conjunto de tweets recientes utilizando la API de X. Se realizaron múltiples solicitudes (*requests*) con una consulta general que incluyó términos relacionados con diferentes desastres como huracanes, inundaciones, tormentas, deslizamientos de tierra y más. Esto permitió obtener un dataset inicial de aproximadamente 4500 tweets, los cuales fueron procesados a través del *pipeline* de clasificación

Tras aplicar el primer modelo (*Informativeness_label*), se determinó que solo 1114 tweets (24.75%) fueron etiquetados como informativos. Esto confirma que una gran cantidad de tweets extraídos no contenían información relevante para la gestión de desastres.

Sin embargo, al analizar los tweets clasificados como informativos, se identificaron algunos casos donde la etiqueta asignada no correspondía al contenido del mensaje. Mostramos algunos ejemplos:

Tweet Original	Modelo 1 (Informatividad)	Modelo 2 (Tipo de desastre)	Modelo 3 (Tipo de información)
‘@Evan_Flood Gross’	Informativo	Floods	Infrastructure and utilities damage
‘Remember to flood our timeline with	Informativo	Floods	Caution and advice

videos...'			
------------	--	--	--

En estos casos, el sistema etiquetó erróneamente tweets que no están relacionados con un desastre real, sino que hacen uso de términos como “*flood*” en contextos no relevantes. Esto sugiere que el Modelo 1 podría beneficiarse de un ajuste en sus criterios de clasificación, reduciendo la probabilidad de clasificar tweets que contienen palabras clave sin relación.

Si bien la consulta general utilizada en esta evaluación permitió obtener una muestra diversa de datos, se observó que el uso de un *query* demasiado amplio puede afectar la precisión del sistema. Como alternativa, se plantea que el rendimiento del *pipeline* podría mejorar significativamente si se enfoca en eventos de desastre específicos en lugar de utilizar una consulta genérica.

Por ejemplo, si se sabe que ha ocurrido un terremoto reciente en Portugal, en lugar de realizar una búsqueda amplia con términos como “*hurricane OR flood OR landslide*”, se podría refinar la consulta para incluir nombres específicos del evento o ubicaciones afectadas. Esto ayuda a reducir la cantidad de tweets irrelevantes en la muestra inicial, aumentar la precisión del Modelo 1, evitando clasificaciones erróneas y obteniendo información más contextualizada y útil para la gestión de desastres. De esta manera, tenemos resultados más precisos como los siguientes:

Tweet Original	Modelo 1 (Informatividad)	Modelo 2 (Tipo de desastre)	Modelo 3 (Tipo de información)
‘The earthquake recorded today with its epicentre in Seixal was felt with maximum intensity in Sintra and Almada and with less intensity in some municipalities in the Central region and the Algarve, revealed the IPMA. #Lisbon #Algarve #earthquake’	Informativo	Earthquake	other useful information
‘Deadliest #earthquake (#terramoto) that occurred in recent years within 300km of #Lisbon (#Portugal): 23/04/1909 a M6.6 led to 30 casualties...’	Informativo	Earthquake	affected individuals
‘#Earthquake 17 km S of #Lisbon	Informativo	Earthquake	infrastructure and

(#Portugal) 31 min ago (local time 13:24:03). Updated map - Colored dots represent local shaking & damage level reported by eyewitnesses. Share your experience via...			utilities damage
--	--	--	------------------

4. PRODUCTO ENTREGABLE

Presentación de resultados en el Dashboard

El dashboard desarrollado constituye el producto final del proyecto, integrando de manera efectiva los resultados del *pipeline* de clasificación de tweets sobre desastres. Su diseño interactivo nos permite una exploración intuitiva de los datos, facilitando el análisis de tendencias y la interpretación de la conversación digital en torno a eventos de desastre.

A través de visualizaciones dinámicas y tablas interactivas, el dashboard brinda una herramienta que permite:

- Evaluar la relevancia de los tweets analizados, diferenciando entre aquellos que contienen información útil y aquellos que no aportan datos significativos. Se observa, por ejemplo, que en el dataset analizado, aproximadamente 21.5% de los tweets fueron clasificados como informativos, lo que destaca la importancia de contar con modelos que filtren contenido relevante.
- Identificar los desastres más mencionados en redes sociales, mediante un gráfico de barras que refleja la distribución de los tweets clasificados. En el dataset que obtuvimos del *pipeline* eventos como huracanes, terremotos e inundaciones presentan la mayor frecuencia, lo que puede indicar su impacto mediático y la preocupación social en torno a estos fenómenos.

Análisis de Tweets sobre Desastres Naturales


Total de Tweets analizados: 14563



- Analizar el tipo de información compartida en los tweets informativos, permitiendo distinguir entre categorías como donaciones y voluntariado, daños en infraestructuras y consejos de precaución. En este caso, la predominancia de la categoría *other useful information* después de *not related or not informative* sugiere que la conversación en

redes sociales sobre desastres es amplia y no siempre se ajusta a categorías predefinidas.

Distribución de Tipos de Información



- Explorar individualmente los tweets analizados, con una tabla que permite verificar los textos originales y su clasificación en cada modelo, ofreciendo transparencia en el proceso de categorización automática.

Text	Model1	Model2	Model3
MBMC #mybmcWardPN #earthquake #Madharasi #ABDevilliers #Chaava #Bitcoin #deprem #justiceforthaifans https://t.co/7QmFF3LQ8x	informative	earthquake infrastructure and utilities damage	
!hi people watching earthquake, yamuna, pollution, traffic, train accident #trainaccident #earthquake https://t.co/tBwqR9bmBt	informative	earthquake	other useful information
ia Dies in a Tragic Road Accident. #earthquake #FreeKizzaBesigye Raila, Ruto, Kiambu, Macron, Gen Z. https://t.co/EL99Yx0WRJ	informative	earthquake	affected individuals
safe. #ABDevilliers #RashmikaMandanna #HrithikRoshan #vivoV50 #Madharasi #earthquake #Picoin #Picoin https://t.co/p0pbrjaJbX	informative	earthquake	caution and advice
Fatal Motor Accident Claims Eight Lives In Imo #MilelEstafador #NuNew #earthquake https://t.co/TlndOFgd05	informative	earthquake	affected individuals
A train accident in Texas #Texas #America #earthquake #trainaccident https://t.co/tJdJF872XC	informative	explosion	other useful information
uke in Delhi has diverted the mind of Delhiites from train accident in Delhi to earthquake. #WellPlayedAshwini11 #earthquake	informative	earthquake	other useful information
: video) then the timing of cctv is which does not happen usually. #earthquake #fakevideo #factcheck https://t.co/gp16GUJwj	informative	earthquake	other useful information
#Earthquake. First morning on my feet after the accident. And Earthquake! 3-minutes ago.	informative	earthquake	other useful information
they only care about their own position. #trainaccident #NewDelhiRailwaystation #earthquake #BeerBiceps #RanveerAllahbadia not related or not informative earthquake (not informative)			not related or not informative

En un contexto de gestión de crisis y toma de decisiones, esta herramienta podría optimizarse con la incorporación de análisis temporales más detallados, integración con mapas de geolocalización y monitoreo en tiempo real. Su escalabilidad permite que pueda adaptarse a nuevas necesidades y evolucionar hacia un sistema más robusto para la detección y análisis de información relevante en situaciones de desastre.

Conclusión

El desarrollo de este proyecto ha permitido la implementación de un sistema integral para la clasificación y análisis de tweets relacionados con desastres. A través del uso de modelos de aprendizaje profundo basados en BERT, logramos estructurar un *pipeline* que permite filtrar información relevante, identificar el tipo de desastre mencionado y clasificar el contenido según su utilidad informativa. La integración con la API de X y el diseño de un dashboard

interactivo facilitaron la exploración de los datos y su presentación de manera visual, convirtiéndolo en una herramienta accesible para el análisis de tendencias en redes sociales durante eventos catastróficos.

Los resultados obtenidos evidencian el potencial de las redes sociales como una fuente de información en tiempo real, aunque también revelan desafíos inherentes al procesamiento de datos no estructurados. A pesar de que los modelos lograron una precisión alta en tareas específicas, la evaluación con tweets recientes mostró limitaciones, particularmente en la identificación de contenido realmente relevante dentro de un volumen masivo de información. La presencia de falsos positivos en la clasificación de tweets informativos y la ambigüedad en algunas categorías sugiere la necesidad de ajustes adicionales en el entrenamiento de los modelos y en la calidad de los datos de entrada.

Uno de los principales hallazgos fue que el sistema tiende a ser más eficiente cuando se aplica a eventos específicos y recientes, en lugar de utilizar consultas generales en la API de X. Esto sugiere que, en futuras implementaciones, se podrían optimizar las estrategias de recolección de datos para mejorar la precisión del modelo y evitar ruido informativo. Además, la limitación impuesta por la membresía básica de la API restringió la cantidad de tweets obtenidos en cada *request*, lo que impactó la capacidad de obtener una muestra más representativa. En futuras versiones del proyecto, una mejora en el acceso a los datos mediante una membresía avanzada de la API permitiría una cobertura más amplia y robusta.

Finalmente, el dashboard desarrollado representa un entregable que permite a los usuarios explorar los datos de manera dinámica y entender la distribución de la información en redes sociales durante desastres. La implementación de filtros interactivos y visualizaciones intuitivas refuerza su utilidad como herramienta de análisis. Como líneas futuras de trabajo, se podría complementar este sistema con modelos de detección de desinformación, análisis de sentimiento y geolocalización avanzada para mejorar la precisión y utilidad del análisis.

5. REFERENCIAS

1. Fernández, R. (2025a, 5 de febrero). *Impacto económico de las catástrofes naturales a nivel mundial de 2000 a 2024*. Statista.
<https://es.statista.com/estadisticas/642605/perdidas-economicas-globales-provocadas-por-las-catastrofes-naturales/>
2. Fernández, R. (2025b, 6 de febrero). *Número de catástrofes naturales a nivel mundial de 2010 a 2024*. Statista.
<https://es.statista.com/estadisticas/641148/catastrofes-naturales-a-nivel-mundial/>
3. Young, J. C., Arthur, R., Spruce, M., & Williams, H. T. P. (2022). *Social sensing of flood impacts in India: A case study of Kerala 2018*. *International Journal of Disaster Risk Reduction*, 74, 102908. <https://doi.org/10.1016/j.ijdr.2022.102908>
4. Ma, G. (2020). *Tweets classification with BERT in the field of disaster management*. Department of Civil Engineering, Stanford University.
<https://web.stanford.edu/class/archive/cs/cs224n/cs224n.1204/reports/custom/15785631.pdf>
5. Olteanu, A., Vieweg, S., & Castillo, C. (2015). What to expect when the unexpected happens: Social media communications across crises. *Proceedings of the ACM 2015 Conference on Computer Supported Cooperative Work and Social Computing (CSCW '15)*, 994–1009. <https://doi.org/10.1145/2675133.2675242>
6. Alam, F., Ofli, F., Imran, M., & Aupetit, M. (2018, May 15). *A Twitter tale of three hurricanes: Harvey, Irma, and Maria*. Qatar Computing Research Institute, Hamad Bin Khalifa University. *arXiv*. <https://arxiv.org/pdf/1805.05144>
7. Padma, T. V. (2022, September 29). *Las redes sociales complementan a la ciencia durante los desastres naturales*. Eos.
<https://eos.org/articles/social-media-supplements-science-during-natural-disasters-spanish>

Todo el código, así como los *notebooks* usados para preprocesar, entrenar modelos y visualizar, se pueden encontrar en el siguiente repositorio de Github:

<https://github.com/TFM-DisasterLab/NLP-y-visualizacion-de-Tweets-sobre-desastres/tree/main>

6. ANEXOS

Entrenamiento de los modelos

Los tres modelos de clasificación desarrollados en este proyecto (*Informativeness_label*, *event*, *InformationType*) fueron entrenados con una estructura similar utilizando BERT-base uncased. Se implementaron la siguientes estrategias para optimizar el rendimiento:

- Validación cruzada: se utilizó StratifiedKFold con 3 o 5 *folds* para evaluar la estabilidad de los modelos en diferentes particiones.
- Se empleó AdamW como optimizador, con una programación lineal del *learning rate* y *dropout* de 0.3 para evitar sobreajuste.
- En algunos modelos, se utilizó un mecanismo de *early stopping* con paciencia de 2 épocas para detener el entrenamiento si la pérdida de validación no mejoraba.
- Se calculó la pérdida (*CrossEntropyLoss*) y F1-score para evaluar el desempeño en cada *fold*.

A continuación se presenta un fragmento representativo del código utilizado en el entrenamiento:

```
from sklearn.model_selection import StratifiedKFold
from transformers import BertForSequenceClassification, AdamW,
get_scheduler
import torch

skf = StratifiedKFold(n_splits=3, shuffle=True, random_state=42)
fold_results = []

for fold, (train_index, val_index) in
enumerate(skf.split(train_df['ProcessedText'], train_labels)):
    print(f"🔄 Fold {fold + 1}")

    # División de datos en train y validación
    train_texts, val_texts =
train_df.iloc[train_index]['ProcessedText'],
train_df.iloc[val_index]['ProcessedText']
    train_labels_fold, val_labels_fold =
```

```

train_labels[train_index], train_labels[val_index]

# Creación de datasets y dataloaders
train_dataset_fold = DisasterDataset(list(train_texts),
train_labels_fold, tokenizer)
val_dataset_fold = DisasterDataset(list(val_texts),
val_labels_fold, tokenizer)

train_loader_fold = DataLoader(train_dataset_fold,
batch_size=32, shuffle=True)
val_loader_fold = DataLoader(val_dataset_fold, batch_size=32)

# Inicialización del modelo BERT
model = BertForSequenceClassification.from_pretrained(
    'bert-base-uncased',
    num_labels=len(label_encoder.classes_), # Cambia según el
modelo
    hidden_dropout_prob=0.3
)
model.to(device)

# Optimización y Scheduler
optimizer = AdamW(model.parameters(), lr=2e-5, eps=1e-8)
loss_fn = torch.nn.CrossEntropyLoss()
scheduler = get_scheduler(
    'linear',
    optimizer=optimizer,
    num_warmup_steps=0,
    num_training_steps=len(train_loader_fold) * 3
)

# Entrenamiento del modelo
for epoch in range(3): # Se usa early stopping si aplica
    model.train()
    total_loss = 0

    for batch in train_loader_fold:
        batch_inputs, batch_labels = batch
        batch_inputs = {key: val.to(device) for key, val in
batch_inputs.items()}
        batch_labels = batch_labels.to(device)

```

```

        outputs = model(**batch_inputs, labels=batch_labels)
        loss = outputs.loss
        total_loss += loss.item()

        optimizer.zero_grad()
        loss.backward()
        optimizer.step()
        scheduler.step()

    # Evaluación en validación
    val_loss, val_report = evaluate(val_loader_fold, model)
    print(f"Epoch {epoch + 1} - Training Loss: {total_loss /
len(train_loader_fold):.4f}, Validation Loss: {val_loss:.4f}")

    fold_results.append(val_loss)

# Resultados finales de validación cruzada
print(f"\n📊 Cross-validation average loss:
{np.mean(fold_results):.4f} ± {np.std(fold_results):.4f}")

```

Este código representa la estructura de entrenamiento utilizada en los tres modelos, con pequeñas variaciones en la cantidad de clases (`num_labels`), el número de *folds* en validación cruzada y la presencia o ausencia de *early stopping*.

El código completo de cada modelo se puede encontrar en el repositorio de [GitHub](#) creado para este proyecto, dentro del folder ‘notebooks’.

Pipeline de procesamiento de datos

El *pipeline* carga los tres modelos de clasificación entrenados previamente, junto con su *tokenizer* y su *label encoder* para interpretar las predicciones.

En el segundo modelo se asigna una etiqueta alternativa para diferenciar tweets no informativos. Así, si un tweet en el primer modelo fue etiquetado como *Not related or not informative*, pero habla sobre un terremoto (*event: earthquake*), será etiquetado como *earthquake (not informative)*.

Los tweets clasificados se almacenan en un dataset histórico. Si ya existe un dataset previo, se combinan ambos y se eliminan tweets duplicados para mantener un historial limpio y actualizado.

Además, el pipeline elimina archivos temporales como notebooks intermedios y el dataset procesado, manteniendo únicamente el dataset final. A continuación se presenta parte del código:

```
# Cargar modelos
tokenizer1, model1 =
load_model("models/bert_informative_classifier_1")
tokenizer2, model2 = load_model("models/bert_event_classifier_2")
tokenizer3, model3 =
load_model("models/bert_information_classifier_3")

# Cargar label encoders
label_encoder1 =
load_label_encoder("models/bert_informative_classifier_1")
label_encoder2 =
load_label_encoder("models/bert_event_classifier_2")
label_encoder3 =
load_label_encoder("models/bert_information_classifier_3")

# Clasificación con los modelos
texts = df_preprocessed["Text"].tolist()
predictions1 = classify_model(texts, tokenizer1, model1)
labels1 = label_encoder1.inverse_transform(predictions1)

# Aplicar modelo 2 solo a tweets informativos
predictions2 =
classify_model(texts, tokenizer2, model2)
labels2 =
[label_encoder2.inverse_transform([p])[0] if l == "informative"
else "Not Available" for l, p in zip(labels1, predictions2)]

predictions3 = classify_model(texts, tokenizer3, model3)
labels3 = label_encoder3.inverse_transform(predictions3)

# Agregar resultados al dataset
df_preprocessed["Model1"] = labels1
df_preprocessed["Model2"] = labels2
df_preprocessed["Model3"] = labels3
```

```
# Guardar dataset histórico
df_preprocessed.to_csv("dataframe_api_historico.csv", index=False)
```

Este código puede expandirse para incorporar nuevas categorías o modelos mejorados en el futuro.

El archivo .py del pipeline completo se halla en el repositorio de [GitHub](#).

API de Twitter

Para la extracción de tweets, el equipo adquirió la membresía básica de la API de X, la cual permite obtener hasta 15.000 tweets al mes. Sin embargo, esta versión impone ciertas limitaciones como:

- Un máximo de 100 tweets por *request*
- Restricción de acceso a datos históricos, permitiendo únicamente la recuperación de tweets recientes.

En futuras implementaciones, una actualización a la membresía profesional permitiría mejorar la eficiencia del *pipeline*, aumentando la capacidad de extracción y permitiendo un análisis más amplio.

Para evitar procesar tweets repetidos, se mantiene un archivo de IDs de tweets ya extraídos (processed_ids.txt). Antes de almacenar nuevos tweets, se verifica que su ID no esté registrado:

```
processed_ids_file = "processed_ids.txt"
if os.path.exists(processed_ids_file):
    with open(processed_ids_file, "r") as f:
        processed_ids = {line.strip() for line in f if
line.strip()}
else:
    processed_ids = set()
```

Se realiza la consulta a la API, solicitando 100 tweets por *request* e incluyendo campos adicionales como ubicación, verificación del usuario y texto del tweet. Los datos se

almacenan en un archivo CSV (tweets.csv), actualizándose con nuevos tweets sin sobrescribir los existentes.

```
response = client.search_recent_tweets(  
    query=query,  
    tweet_fields=["author_id", "created_at", "id", "geo"],  
    user_fields=["location", "verified"],  
    expansions=["author_id"],  
    max_results=100  
)
```

Para mejorar el rendimiento del *pipeline* en el futuro también se podría implementar paginación para extraer más de 100 tweets por ejecución y filtrar tweets por relevancia mediante técnicas adicionales de NLP antes de enviarlos a la clasificación con BERT.